

数据挖掘与可视化复习提示

1、考试形式：25 道单选题，4 道大题（每道大题有若干小问）

2、识记、辨析、简单运用类知识点：

- a) Level of measurement (nominal、ordinal、interval、range)，识记概念，关注课上实例
- b) Upsampling in binary classification，理解二分类中上采样的目的和实现方法
- c) Dataset transformation 相关概念，如 dummy coding、data downsampling、split-apply-combine、bucketing（概念和实例）
- d) Grammar of Graphics 数据可视化的各层核心组件
- e) 相关性与距离测度：sample Pearson correlation coefficient、 R^2 、population Pearson correlation coefficient、Pseudo- R^2 for classification（定义、公式含义）
- f) 相关性表述：强正相关、强负相关、弱正相关、弱负相关（注意课堂实例，能从 scatter plot 上识别相关性）
- g) NHST（全称、概念、该方法结果受哪些因素影响）
- h) 回归模型的性能指标/损失函数设计：SSE、MSE、RMSE、 R^2 （定义、数学形式）
- i) 回归模型的假设（hypothesis）：尤其识别自变量、因变量（独立变量）
- j) 信息熵的概念（关注课堂简单实例，例如 fair coin flip 的熵应该是多少？）
- k) 决策树的剪枝（pruning a decision tree）：目的、方法/过程/步骤、与 overfitting/regularization 的关系
- l) 给定 confusion matrix，能正确计算 sensitivity、specificity
- m) Discriminative classifier 的概念、实例（例如识别 logistic regression、naïve Bayes classifier、decision trees、SVMs 哪些是 discriminative classifiers）
- n) SVM 中 kernel function 的作用
- o) K-means 的概念、步骤/过程/方法、特性（如是否具有初值敏感性）
- p) Dendrogram 的概念、形式、绘制过程、主要应用
- q) PCA 的概念、过程/方法，尤其是“主成分（Principal Component）”的含义
- r) 关联规则的置信度（confidence of an association rule）的概念、简单实例、置信度的数学形式
- s) 关联规则挖掘中 Apriori principle 的概念、具体实例
- t) Dynamic time warping (DTW) 概念、过程/步骤/方法、主要优、劣势
- u) Jaccard coefficient 的概念与作用
- v) The process of separating the foreground pixels from the background 使用哪个图像处理技巧（没有看课件，我猜是 thresholding，但建议对应课件确认，其他给出的操作是 erosion、dilation、skeletonization。严格而言，这道题其实出得有问题，必须上过课才会答，如果让我答我会说 foreground-background segmentation，但显然没有这个选项）

3、综合运用类知识点：

- a) 利用 Apriori algorithm 挖掘 association rules (给出的例子是文具店购物的交易记录, 每次交易购买了不同的文具)。给定 minimum support, 构建 frequent itemsets; 给定 minimum confidence, 基于构建的 frequent itemsets 给出 association rules。(去年也这么考过, 肯定在作业或例题里有)
- b) 给出潜在客户数据集 (客户年龄、工资等级、最终是否购买商品等), 构建决策树预测新客户是否会购买商品。一些常见的 2 为底数的对数会列表给出。证明整个数据集的熵为 1; 选择某个 feature 为根节点, 计算其 information gain; 根据不同 feature 根节点时的 information gain, 给出选择某个 feature 作为根节点构造决策树的理由。(去年有很类似的考法, 应该也是参考了作业题或例题)
- c) 给定多个数据点间的距离矩阵 (proximity matrix), 利用 agglomerative hierarchical clustering 进行聚类。须利用 MIN (Single Link) 或 MAX (Complete Linkage) 更新距离矩阵并绘制 dendrogram。此外, 须了解还有哪些可以作为 inter-cluster similarity measure 的测度可用于聚类。(我记得以前有学生拿着作业题问过我, 应该也是见过的题目)
- d) 给出一个时间序列基于 Piecewise Aggregate Approximation (PAA) 的五个分段 (以及符号和 breakpoints 列表), 根据 breakpoint 信息计算该时间序列的 Symbolic Aggregate Approximation (SAX) 表示。(应该是例题或作业题)

(备注: 不涉及 resit; 因工作安排繁忙, 无法回应套题式提问。)