

MAIE 5532 — 期中考试示例 2（60 分钟）

第 1–5 周：框架、自动微分（AD）、计算图优化、并行计算、分布式/联邦学习

说明：请勾选所选选项左侧的方框。部分题目为多选题。

姓名：请填写姓名

学号：请填写学号

题目（40 题）

第 1 题

对于包含数百万参数的标量损失，哪种自动微分模式能最高效地计算向量-雅可比积？

- ☐ A. 前向模式自动微分
- ☐ B. 反向模式自动微分
- ☐ C. 数值有限差分
- ☐ D. 仅使用纯符号微分

知识点： 反向模式自动微分适合参数众多、损失为标量的梯度计算。

课件位置： 第 2 周课件，第 32 页; 第 2 周课件，第 47 页 **复习页 PDF：** 涵盖本题全部选项知识点的课件页

[查看答案与解析](#)

第 2 题

对于对偶数，单变量函数满足 $f(a + \epsilon \cdot b) = ?$ （一阶精确）

- ☐ A. $f(a) + f''(a) \cdot \epsilon \cdot b$
- ☐ B. $f(a) + f'(a) \cdot b^2$
- ☐ C. $f(a) + f'(a) \cdot \epsilon \cdot b$
- ☐ D. $f(a)$ （不变）

知识点： 对偶数求值遵循一阶泰勒展开规则。

课件位置： 第 2 周课件，第 13–15 页 **复习页 PDF：** 涵盖本题全部选项知识点的课件页

[查看答案与解析](#)

第 3 题

在 TensorFlow Lite for Microcontrollers（TFLM）中，推理的核心内存策略是：

- ☐ A. 每次推理都依赖 malloc/free
- ☐ B. 使用操作系统分页来超额分配 RAM
- ☐ C. 运行时将所有激活存储在外部闪存

- ☐ D. 提供固定的张量 arena，并避免在热点路径进行动态分配

知识点： TFLM 使用固定张量 arena，避免热点路径中的动态分配。

课件位置： 第 1 周课件，第 55 页 **复习页 PDF：** 涵盖本题全部选项知识点的课件页

[查看答案与解析](#)

第 4 题

在基于 XLA 的 JIT 编译（例如 JAX/TF）中，主要优势是什么？

- ☐ A. 保证零内存使用
- ☐ B. 算子融合、布局选择和缓冲区复用
- ☐ C. 无需自动微分
- ☐ D. 无需重新追踪即可支持任意动态形状

知识点： XLA JIT：算子融合、布局选择与缓冲区复用。

课件位置： 第 3 周课件，第 37 页 **复习页 PDF：** 涵盖本题全部选项知识点的课件页

[查看答案与解析](#)

第 5 题

配合 `-ffunction-sections/-fdata-sections` 使用时，哪种链接器选项会从最终二进制文件中删除未使用的代码/数据？

- ☐ A. `-Os`
- ☐ B. `-flto`
- ☐ C. `-fno-plt`
- ☐ D. `--gc-sections`

知识点： 通过段垃圾回收和链接器选项缩减嵌入式代码体积。

课件位置： 第 4 周课件，第 58 页 **复习页 PDF：** 涵盖本题全部选项知识点的课件页

[查看答案与解析](#)

第 6 题

哪种分层 All-Reduce 顺序正确？

- ☐ A. 节点间 All-Gather → 节点内 Reduce-Scatter → 节点间 Reduce-Scatter → 节点内 All-Gather
- ☐ B. 节点内 All-Gather → 节点间 All-Gather → 节点内 Reduce-Scatter → 节点间 Reduce-Scatter
- ☐ C. 节点内 Reduce-Scatter → 节点间 Reduce-Scatter → 节点间 All-Gather → 节点内 All-Gather
- ☐ D. 节点间 Reduce-Scatter → 节点内 Reduce-Scatter → 节点间 All-Gather → 节点内 All-Gather

知识点： 分层 All-Reduce 的四个通信阶段。

课件位置： 第 5 周课件，第 17 页 **复习页 PDF：** 涵盖本题全部选项知识点的课件页

[查看答案与解析](#)

第 7 题

在联邦学习的安全聚合中，处理客户端掉线通常需要：

- ☐ A. 服务器解密所有更新
- ☐ B. 从日志重放客户端更新
- ☐ C. 对原始音频执行同态推理
- ☐ D. 通过阈值掩码恢复机制，确保成对掩码仍能在总和中抵消

知识点： 安全聚合通过阈值掩码恢复机制处理客户端掉线。

课件位置： 第 5 周课件，第 50 页 **复习页 PDF：** 涵盖本题全部选项知识点的课件页

[查看答案与解析](#)

第 8 题

在 TensorFlow 2.x 中，默认执行风格是：

- ☐ A. 即时（命令式）执行，可选用 `tf.function`
- ☐ B. 仅使用会话执行静态图
- ☐ C. 仅进行提前编译
- ☐ D. 仅使用类似 TorchScript 的追踪

知识点： TensorFlow 2.x 的即时执行及可选 `tf.function`。

课件位置： 第 1 周课件，第 35 页; 第 1 周课件，第 49 页 **复习页 PDF：** 涵盖本题全部选项知识点的课件页

[查看答案与解析](#)

第 9 题

TensorFlow 1.x 的“先定义后执行”(define-then-run) 对应于：

- ☐ A. 立即执行
- ☐ B. 纯函数式变换
- ☐ C. 在 Session 中执行的符号计算图
- ☐ D. 没有计算图的纯设备内核

知识点： TensorFlow 1.x 的先定义后执行符号图与 Session 执行。

课件位置： 第 1 周课件，第 41 页 **复习页 PDF：** 涵盖本题全部选项知识点的课件页

[查看答案与解析](#)

第 10 题

在 TFLM 中，FlatBuffer 模型格式主要实现什么？

- ☐ A. 在 MCU 上进行在线反向传播
- ☐ B. 零拷贝、经过 schema 校验的访问，且无需繁重解析

- ☐ C. 针对每个模型在设备端生成代码
- ☐ D. 运行时动态链接算子

知识点： FlatBuffers 支持 MCU 上基于 schema 的零拷贝模型访问。

课件位置： 第 1 周课件，第 62–64 页 **复习页 PDF：** 涵盖本题全部选项知识点的课件页

[查看答案与解析](#)

第 11 题

在 TinyML 系统中，主要能耗往来自：

- ☐ A. ALU 加法
- ☐ B. 分支预测
- ☐ C. 栈帧建立
- ☐ D. 无线电上行传输（例如 BLE/Wi-Fi）

知识点： TinyML 能耗，尤其是无线电上行传输成本。

课件位置： 第 4 周课件，第 35 页; 第 6 周课件，第 26 页 **复习页 PDF：** 涵盖本题全部选项知识点的课件页

[查看答案与解析](#)

第 12 题

CNN 模块中，哪种典型融合可以减少内存流量？

- ☐ A. BatchNorm → Softmax → Dropout
- ☐ B. Pool → Pool → Pool
- ☐ C. Conv2D → BatchNorm → ReLU
- ☐ D. ReLU → Argmax → Sort

知识点： Conv2D–BatchNorm–ReLU 融合可减少内存流量和内核启动。

课件位置： 第 3 周课件，第 21–22 页 **复习页 PDF：** 涵盖本题全部选项知识点的课件页

[查看答案与解析](#)

第 13 题

对于 NHWC 张量，缓存友好的内层循环通常采用哪种遍历顺序？

- ☐ A. $h \rightarrow w \rightarrow c$ (c 为最内层)
- ☐ B. $c \rightarrow h \rightarrow w$ (c 为最外层)
- ☐ C. 随机步长
- ☐ D. $h \rightarrow c \rightarrow w$ (w 为最外层)

知识点： NHWC 布局与通道维连续遍历。

课件位置： 第 3 周课件，第 25–26 页; 第 6 周课件，第 67 页 **复习页 PDF：** 涵盖本题全部选项知识点的课件页

[查看答案与解析](#)

第 14 题

以下哪项不是同步 All-Reduce 训练的特征？

- ☐ A. 每步都有全局屏障
- ☐ B. 按设计会在工作节点间产生权重陈旧
- ☐ C. 等价于使用全局批次的单设备训练
- ☐ D. 对慢速节点敏感

知识点： 同步 All-Reduce 有逐步屏障且受慢速节点影响，但并非设计上允许权重陈旧。

课件位置： 第 5 周课件，第 16 页 **复习页 PDF：** 涵盖本题全部选项知识点的课件页

[查看答案与解析](#)

第 15 题

参数服务器（异步/陈旧同步）方法的实际优势是：

- ☐ A. 没有陈旧问题
- ☐ B. 吞吐量更高且能容忍慢速客户端
- ☐ C. 与单设备 SGD 完全等价
- ☐ D. 不同运行之间完全可复现

知识点： 异步参数服务器以权重陈旧风险换取吞吐量和对慢速客户端的容忍度。

课件位置： 第 5 周课件，第 15-16 页 **复习页 PDF：** 涵盖本题全部选项知识点的课件页

[查看答案与解析](#)

第 16 题

在 ZeRO 阶段 2 中，优化器分片的是：

- ☐ A. 仅参数张量
- ☐ B. 优化器状态和梯度
- ☐ C. 仅参数，其他不分片
- ☐ D. 什么都不分片（只融合内核）

知识点： ZeRO 阶段 2 对优化器状态和梯度进行分片。

课件位置： 第 5 周课件，第 18 页 **复习页 PDF：** 涵盖本题全部选项知识点的课件页

[查看答案与解析](#)

第 17 题

在分片训练中，哪一阶段会计算部分归约并将结果分配到各 rank？

- ☐ A. All-Gather

- ☐ B. Broadcast
- ☐ C. All-to-All
- ☐ D. Reduce-Scatter

知识点： Reduce-Scatter 将归约与跨 rank 分区结合起来。

课件位置： 第 5 周课件，第 17-18 页 **复习页 PDF：** 涵盖本题全部选项知识点的课件页

[查看答案与解析](#)

第 18 题

如果初始化时 TFLM 张量 arena 太小，正确行为是：

- ☐ A. 静默地在堆上重新分配
- ☐ B. 原地压缩模型
- ☐ C. 立即返回初始化错误
- ☐ D. 自动从闪存流式读取张量

知识点： TFLM 固定 arena 容量不足时应在初始化阶段报错。

课件位置： 第 1 周课件，第 55 页 **复习页 PDF：** 涵盖本题全部选项知识点的课件页

[查看答案与解析](#)

第 19 题

MLIR 最适合如何描述？

- ☐ A. 多层级编译器框架，使用方言支持从 TF 算子到 LLVM 的变换
- ☐ B. 替代 TF Serving 的运行时
- ☐ C. 仅用于图形可视化的工具
- ☐ D. 用于 GEMM 的 GPU 厂商库

知识点： MLIR 是使用方言进行多层级变换的编译器基础设施。

课件位置： 第 3 周课件，第 39 页 **复习页 PDF：** 涵盖本题全部选项知识点的课件页

[查看答案与解析](#)

第 20 题

哪种方法明确地先在节点内部归约，以减少跨交换机流量？

- ☐ A. 环形 All-Reduce
- ☐ B. 树形 All-Reduce
- ☐ C. 参数服务器
- ☐ D. 分层 All-Reduce

知识点： 分层 All-Reduce 先进行节点内归约，再进行节点间通信。

课件位置： 第 5 周课件，第 17 页 **复习页 PDF：** 涵盖本题全部选项知识点的课件页

[查看答案与解析](#)

第 21 题

联邦学习中讨论的一种个性化策略是：

- ☐ A. 仅保留服务器端的头部并冻结所有客户端层
- ☐ B. 上传所有个人参数以进行全局平均
- ☐ C. 拆分模型：共享主干进行全局聚合，私有头部保留在设备端
- ☐ D. 仅在设备上训练嵌入层，然后丢弃其他部分

知识点： 联邦学习个性化：全局共享主干与设备端私有头部。

课件位置： 第 5 周课件，第 44 页 **复习页 PDF：** 涵盖本题全部选项知识点的课件页

[查看答案与解析](#)

第 22 题

针对非 IID 数据，哪种聚合策略可以改善收敛？

- ☐ A. 按群组聚合：先在群组内平均，再合并
- ☐ B. 只按网络速度加权
- ☐ C. 丢弃少数群组
- ☐ D. 只聚合最大的客户端

知识点： 针对非 IID 客户端数据的群组内聚合。

课件位置： 第 5 周课件，第 45–46 页 **复习页 PDF：** 涵盖本题全部选项知识点的课件页

[查看答案与解析](#)

第 23 题

在联邦学习的客户端级差分隐私中，添加噪声前用什么限制单个客户端的影响？

- ☐ A. 动量校正
- ☐ B. 逐客户端范数裁剪
- ☐ C. 同态加密
- ☐ D. 安全飞地

知识点： 客户端级差分隐私通过逐客户端范数裁剪限制单个客户端的影响。

课件位置： 第 5 周课件，第 49 页 **复习页 PDF：** 涵盖本题全部选项知识点的课件页

[查看答案与解析](#)

第 24 题

在 DDP 中，梯度分桶的主要用途是什么？

- ☐ A. 增加峰值内存

- ☐ B. 通过剪枝张量来减少浮点运算
- ☐ C. 对就绪的桶启动 All-Reduce, 使通信与计算重叠
- ☐ D. 安全地禁用混合精度

知识点： DDP 梯度分桶使 All-Reduce 通信与反向传播重叠。

课件位置： 第 5 周课件, 第 7 页 **复习页 PDF：** 涵盖本题全部选项知识点的课件页

[查看答案与解析](#)

第 25 题

DL 框架中常用作后备方案、支持 CPU/GPU 集合通信的通用库是：

- ☐ A. NCCL
- ☐ B. MPI
- ☐ C. Gloo
- ☐ D. NVSHMEM

知识点： Gloo 是通用的 CPU/GPU 集合通信库。

课件位置： 第 5 周课件, 第 17 页 **复习页 PDF：** 涵盖本题全部选项知识点的课件页

[查看答案与解析](#)

第 26 题

在 TPU 上, 提升脉动阵列利用率的常见做法是：

- ☐ A. 使用许多小型 GEMM
- ☐ B. 将矩阵维度填充/对齐到偏好的倍数 (例如 128)
- ☐ C. 禁用 XLA 的布局选择
- ☐ D. 默认将所有卷积替换为 FFT

知识点： TPU 脉动阵列与矩阵维度分块对齐。

课件位置： 第 6 周课件, 第 12 页; 第 6 周课件, 第 16 页 **复习页 PDF：** 涵盖本题全部选项知识点的课件页

[查看答案与解析](#)

第 27 题

对于小型消息, 哪种归约算法通常延迟更低？

- ☐ A. 树形 All-Reduce
- ☐ B. 环形 All-Reduce
- ☐ C. All-to-All
- ☐ D. 广播

知识点： 树形 All-Reduce 可降低小消息场景的延迟。

课件位置： 第 5 周课件, 第 17 页 **复习页 PDF：** 涵盖本题全部选项知识点的课件页

[查看答案与解析](#)

第 28 题

哪种图级变换可以避免重复计算相同的子图？

- ☐ A. 内核内联
- ☐ B. 冻结层
- ☐ C. 梯度检查点
- ☐ D. 公共子表达式消除

知识点： 公共子表达式消除可避免重复计算图子表达式。

课件位置： 第 3 周课件，第 28–30 页 **复习页 PDF：** [涵盖本题全部选项知识点的课件页](#)

[查看答案与解析](#)

第 29 题

(可多选) 讨论过的代码体积优化方法包括：

- ☐ A. 使用 -Os 编译以减小体积
- ☐ B. 使用链接时优化 (LTO)
- ☐ C. 在 -ffunction-sections/-fdata-sections 后使用 --gc-sections 链接
- ☐ D. 在发布版本中启用详细日志字符串

知识点： 使用 -Os、LTO 和 --gc-sections 缩减嵌入式代码体积。

课件位置： 第 4 周课件，第 58 页 **复习页 PDF：** [涵盖本题全部选项知识点的课件页](#)

[查看答案与解析 \(多选\)](#)

第 30 题

(可多选) 计算图的优势包括：

- ☐ A. 基于有向无环图 (DAG) 上的链式法则进行自动微分
- ☐ B. 提供全局调度和内核融合机会
- ☐ C. 支持内存规划和缓冲区复用
- ☐ D. 保证消除所有通信

知识点： 计算图支持自动微分、全局优化与内存规划。

课件位置： 第 1 周课件，第 39–43 页 **复习页 PDF：** [涵盖本题全部选项知识点的课件页](#)

[查看答案与解析 \(多选\)](#)

第 31 题

(可多选) 高效通信的联邦学习更新可以采用：

- ☐ A. 量化 (例如 8/4/2 位，使用逐张量缩放因子)

- ☐ B. 稀疏化并配合误差反馈
- ☐ C. 低秩适配器（例如 LoRA）
- ☐ D. 发送更大的原始样本差分

知识点： 高通信效率的联邦更新：量化、稀疏化与 LoRA。

课件位置： 第 5 周课件，第 23 页 **复习页 PDF：** 涵盖本题全部选项知识点的课件页

[查看答案与解析（多选）](#)

第 32 题

(可多选) 适合 TPU 脉动阵列的 GEMM 分块包括：

- ☐ A. 将 A 和 B 分成固定大小的块
- ☐ B. 填充边界以对齐分块
- ☐ C. A 在单元间水平传递，B 垂直传递
- ☐ D. 每步随机更改分块大小以避免规律性

知识点： TPU 脉动阵列 GEMM 分块与操作数流动。

课件位置： 第 3 周课件，第 24–25 页; 第 6 周课件，第 16 页 **复习页 PDF：** 涵盖本题全部选项知识点的课件页

[查看答案与解析（多选）](#)

第 33 题

(可多选) 针对非 IID 和噪声的稳健联邦学习聚合可以采用：

- ☐ A. 截尾均值/逐坐标中位数
- ☐ B. 更新范数裁剪
- ☐ C. 异常值过滤
- ☐ D. 始终只按客户端 RTT 加权

知识点： 针对非 IID 和含噪更新的稳健联邦聚合。

课件位置： 第 5 周课件，第 45–46 页; 第 5 周课件，第 49 页 **复习页 PDF：** 涵盖本题全部选项知识点的课件页

[查看答案与解析（多选）](#)

第 34 题

(可多选) 大规模可复现性建议包括：

- ☐ A. 为 Python/NumPy/框架/CUDA 随机数生成器设种子
- ☐ B. 在检查点中保存随机数状态和数据加载器轮次/偏移量
- ☐ C. 固定环境版本（CUDA/cuDNN/NCCL、驱动、框架）
- ☐ D. 优先选择非确定性内核以加快运行

知识点： 大规模可复现性：随机数设种子、状态保存与版本固定。

课件位置： 第 5 周课件，第 19–20 页 **复习页 PDF：** 涵盖本题全部选项知识点的课件页

[查看答案与解析（多选）](#)

第 35 题

(可多选) TFLM 在 MCU 上的良好内存实践包括：

- ☐ A. 使用固定张量 arena；不足时快速失败
- ☐ B. 避免在热点路径中 malloc/free
- ☐ C. 预先分配/复用缓冲区以避免碎片
- ☐ D. 每次推理都按层动态分配

知识点： TFLM 使用固定 arena 进行内存规划并复用缓冲区。

课件位置： 第 1 周课件，第 55 页；第 6 周课件，第 23 页 **复习页 PDF：** 涵盖本题全部选项知识点的课件页

[查看答案与解析（多选）](#)

第 36 题

(可多选) FSDP 通常会：

- ☐ A. 在计算前即时 All-Gather 参数分片
- ☐ B. 每层计算后及时释放完整参数
- ☐ C. 在反向传播后对梯度执行 Reduce-Scatter
- ☐ D. 要求所有 rank 始终持有完整参数

知识点： FSDP 即时参数 All-Gather 与梯度 Reduce-Scatter。

课件位置： 第 5 周课件，第 18 页 **复习页 PDF：** 涵盖本题全部选项知识点的课件页

[查看答案与解析（多选）](#)

第 37 题

(可多选) 流水线并行的调节参数/权衡包括：

- ☐ A. 增加微批次数 b 以缩小气泡 $((m-1)/b)$
- ☐ B. 1F1B 减少激活占用，但可能引入权重陈旧
- ☐ C. 激活检查点以额外计算换取更少内存
- ☐ D. GPipe 总是按微批次交错执行前向/反向

知识点： 流水线微批次、气泡缩减、1F1B 与检查点权衡。

课件位置： 第 5 周课件，第 11–12 页；第 2 周课件，第 40 页 **复习页 PDF：** 涵盖本题全部选项知识点的课件页

[查看答案与解析（多选）](#)

第 38 题

(可多选) 降低串行比例 s 或隐藏通信的策略包括:

- ☐ A. 通过分桶和融合内核重叠通信/计算
- ☐ B. 使用低精度或压缩梯度并配合误差反馈
- ☐ C. 增大本地批次, 并审慎考虑部分/延迟同步
- ☐ D. 忽略慢速节点并移除健康检查

知识点: 重叠通信与计算的扩展性策略。

课件位置: 第 5 周课件, 第 7 页; 第 5 周课件, 第 14–17 页; 第 5 周课件, 第 23 页 **复习页 PDF:** 涵盖本题全部选项知识点的课件页

[查看答案与解析 \(多选\)](#)

第 39 题

(可多选) 考虑内存带宽的内核实践包括:

- ☐ A. 让循环顺序与布局 (NHWC/NCHW) 匹配, 以连续访问内存
- ☐ B. 安全时使用原地操作以减少一半流量
- ☐ C. 优先使用许多小内核启动以改善“交错”
- ☐ D. 使用内存池/arena 以避免运行时分配/释放开销

知识点: 内存带宽优化: 连续访问、原地操作与内存池。

课件位置: 第 3 周课件, 第 25–26 页; 第 6 周课件, 第 67–69 页 **复习页 PDF:** 涵盖本题全部选项知识点的课件页

[查看答案与解析 \(多选\)](#)

第 40 题

(可多选) world size 变化时的弹性分布式训练策略包括:

- ☐ A. 重新计算有效全局批次, 并相应调整学习率
- ☐ B. 重建进程组, 并重新分片数据/检查点
- ☐ C. 若精度不变, 则保持损失缩放一致
- ☐ D. 禁用检查点以避免不匹配

知识点: world size 变化时的弹性训练: 批次/学习率、进程组与检查点重分片。

课件位置: 第 5 周课件, 第 5 页; 第 5 周课件, 第 16–20 页 **复习页 PDF:** 涵盖本题全部选项知识点的课件页

[查看答案与解析 \(多选\)](#)

答案与解析

第 1 题

B — 对于参数很多的标量损失（典型神经网络训练），反向模式自动微分效率更高。

[返回顶部](#)

第 2 题

C — 因 $\varepsilon^2=0$, $f(a+\varepsilon b)=f(a)+f'(a)\cdot\varepsilon\cdot b$ 。

[返回顶部](#)

第 3 题

D — TFLM 使用固定张量 arena；热点路径不使用 malloc/free。

[返回顶部](#)

第 4 题

B — XLA 融合算子、选择布局，并复用缓冲区，从而提升速度/效率。

[返回顶部](#)

第 5 题

D — `--gc-sections` 会删除未使用的段（配合 `-ffunction/-fdata-sections` 使用）。

[返回顶部](#)

第 6 题

C — 标准顺序为节点内 Reduce-Scatter → 节点间 Reduce-Scatter → 节点间 All-Gather → 节点内 All-Gather。

[返回顶部](#)

第 7 题

D — 成对掩码会相互抵消；阈值恢复机制可处理安全聚合中的掉线。

[返回顶部](#)

第 8 题

A — TF 2.x 默认采用即时执行；`tf.function` 可追踪/编译热点路径。

[返回顶部](#)

第 9 题

C — TF 1.x 使用在 Session 中执行的符号图（先定义后执行）。

[返回顶部](#)

第 10 题

B — FlatBuffer 可在 MCU 上进行经过 schema 校验的零拷贝访问，无需重型解析。

[返回顶部](#)

第 11 题

D — 无线电通信能耗通常占主导；本地计算可减少传输字节。

[返回顶部](#)

第 12 题

C — Conv + BN + ReLU 融合是减少内存流量/内核启动的常见做法。

[返回顶部](#)

第 13 题

A — 对 NHWC，按 $h \rightarrow w \rightarrow c$ 遍历可连续读取 c 维，从而改善缓存/合并访问。

[返回顶部](#)

第 14 题

B — 同步 All-Reduce 按设计不会产生权重陈旧；它有逐步屏障且对慢速节点敏感，也等价于使用大批次的单设备训练（优化器/计划相同）。

[返回顶部](#)

第 15 题

B — 异步参数服务器可提高吞吐量并容忍慢速客户端（但存在陈旧风险）。

[返回顶部](#)

第 16 题

B — ZeRO-2 对优化器状态和梯度进行分片，以减少内存/流量。

[返回顶部](#)

第 17 题

D — Reduce-Scatter 会执行部分归约，并将结果分配到各 rank。

[返回顶部](#)

第 18 题

C — arena 不足时，TFLM 必须快速失败（确定性优先于静默回退）。

[返回顶部](#)

第 19 题

A — MLIR 是多层级编译器框架 (TF 方言 $\rightarrow$ linalg $\rightarrow$ LLVM IR)，不是运行时。

[返回顶部](#)

第 20 题

D — 分层 All-Reduce 先在节点内归约，再进行节点间通信，从而减少跨交换机流量。

[返回顶部](#)

第 21 题

C — 全局聚合共享主干，同时将私有头部留在设备端，是常见的联邦学习个性化拆分方式。

[返回顶部](#)

第 22 题

A — 先在群组内聚合、再合并，可缓解非 IID 数据偏差并加快收敛。

[返回顶部](#)

第 23 题

B — 裁剪每个客户端更新的范数；之后添加校准噪声以提供客户端级 DP 保证（并使用隐私会计器）。

[返回顶部](#)

第 24 题

C — 分桶会尽早启动 All-Reduce，使通信与剩余反向传播计算重叠。

[返回顶部](#)

第 25 题

C — Gloo 是常用的通用 CPU/GPU 集合通信库后备方案（NCCL 更偏向 GPU）。

[返回顶部](#)

第 26 题

B — 将维度填充/对齐到 TPU 分块大小可提升脉动阵列利用率。

[返回顶部](#)

第 27 题

A — 相比环形算法，树形 All-Reduce 对小型消息通常延迟更低（跳数更少）。

[返回顶部](#)

第 28 题

D — 公共子表达式消除避免重复计算子图，并可与融合/调度优化互补。

[返回顶部](#)

第 29 题

A、B、C — -Os、LTO 和 --gc-sections 可缩小二进制文件；详细日志会增加体积。

[返回顶部](#)

第 30 题

A、B、C — 计算图支持自动微分、全局优化和内存规划（但不保证消除通信）。

[返回顶部](#)

第 31 题

A、B、C — 量化、稀疏化+误差反馈、低秩适配器可减少传输字节；不发送原始数据。

[返回顶部](#)

第 32 题

A、B、C — 固定分块并填充边界，A 向右、B 向下传递；随机分块会破坏规律性和利用率。

[返回顶部](#)

第 33 题

A、B、C — 截尾均值/中位数、更新裁剪和异常值过滤；不应只按 RTT 加权。

[返回顶部](#)

第 34 题

A、B、C — 设定随机种子、保存状态、固定版本可提升可复现性；非确定性内核会破坏可复现性。

[返回顶部](#)

第 35 题

A、B、C — 固定 arena、不在热点路径动态分配、复用缓冲区；避免 MCU 上每次推理都 malloc。

[返回顶部](#)

第 36 题

A、B、C — FSDP 即时 All-Gather 参数、及时释放，并对梯度执行 Reduce-Scatter；不要求始终持有完整参数。

[返回顶部](#)

第 37 题

A、B、C — 增大 b 可缩小气泡；1F1B 降低内存但可能有陈旧；检查点以计算换内存；GPipe 是先全部前向、再全部反向。

[返回顶部](#)

第 38 题

A、B、C — 重叠通信/计算、压缩梯度、调整批次/同步方式可降低 s ；忽略慢速节点会损害稳定性。

[返回顶部](#)

第 39 题

A、B、D — 连续访问、安全的原地操作及分配器/内存池有帮助；大量小内核启动会降低吞吐量。

[返回顶部](#)

第 40 题

A、B、C — 重新计算有效批次和学习率；重建进程组/重新分片；精度不变时保持损失缩放；不要禁用检查点。

[返回顶部](#)